

1 번 문제

단일 RGB 프레임만 입력받는 일반 CNN 이 action recognition 에서 갖는 근본적 한계를 쓰고, two-stream 구조가 이를 어떤 방식으로 보완하는지 설명하시오.

(답)

- 한 프레임은 *외형(appearance)* 만 담고 시간/움직임 정보가 없음 → 정지 화면이 비슷한 행동을 구분하기 어려움
- two-stream 은 spatial(RGB = 외형) + temporal(optical flow = 움직임) 두 경로로 분리
- 무엇이 보이는가와 어떻게 움직이는가 라는 상보적(complementary) 단서를 따로 학습한 뒤 융합

2 번 문제

Temporal stream 의 입력으로 쓰이는 optical flow 가 무엇을 나타내는지, 입력 채널 수가 왜 2L 이 되는지, 그리고 그것이 한 장의 RGB 프레임이 줄 수 없는 어떤 정보를 제공하는지 설명하시오.

(답)

- optical flow = 연속 두 프레임 사이의 픽셀별 변위 (u, v) (수평·수직 성분)
- flow 한 장 = 2 채널, L 장을 쌓으므로 2L 채널
- 정지 외형이 아닌 단기 움직임(방향·크기) 을 명시적으로 제공 → 배경(정지)은 억제되고 움직이는 객체가 강조됨

3 번 문제

작은 규모의 image classification dataset 에서는 CNN 계열 모델이 ViT 보다 안정적으로 학습되는 경우가 많지만, 대규모 dataset 또는 대규모 pretraining 환경에서는 ViT 계열 모델이 강한 성능을 보일 수 있다. 이 현상이 발생하는 구조적 이유를 설명하시오.

(답)

- CNN 은 이미지를 2D feature map 으로 유지하면서 local convolution 을 적용한다. Convolution 은 가까운 픽셀들이 중요한 패턴을 만든다는 locality 를 활용하고, 같은 filter 를 여러 spatial location 에 공유하여 local pattern 을 검출한다. 또한 convolution layer 는 입력이 이동하면 feature map 도 그에 맞게 이동하는 translation equivariance 성질을 가진다. 따라서 CNN 은 이미지의 local structure 를 구조적으로 잘 활용할 수 있어, 비교적 작은 dataset 에서도 안정적으로 feature 를 학습할 수 있다.
- 반면 ViT 는 이미지를 patch 로 나누고 각 patch 를 token 으로 변환한 뒤 self-attention 을 적용한다. Self-attention 은 patch token 들 사이의 관계를 직접 학습할 수 있어, 이미지의 여러 영역 사이의 관계를 유연하게 모델링할 수 있다. 그러나 self-

attention 자체는 token 의 순서나 위치를 알지 못하므로, positional encoding 을 통해 각 patch 의 spatial position 을 알려주어야 한다.

- 따라서 작은 dataset 에서는 이미지의 local structure 를 구조적으로 활용하는 CNN 계열 모델이 더 안정적으로 학습될 수 있다. 하지만 dataset 이나 pretraining 규모가 충분히 커지면, ViT 는 patch token 들 사이의 관계를 self-attention 으로 학습하면서 더 유연한 image representation 을 만들 수 있다. 그래서 대규모 환경에서는 ViT 계열 모델이 강한 image classification 성능을 보일 수 있다.

4 번 문제

VGGNet 과 ResNet 은 ImageNet classification 성능을 높이기 위해 더 깊은 CNN 구조를 사용하였다. VGGNet 이 작은 3×3 convolution 을 반복적으로 사용한 이유를 설명하고, ResNet 이 residual connection 을 도입한 배경을 설명하시오.

(답)

VGGNet

- VGGNet 은 큰 convolution filter 를 사용하는 대신 작은 3×3 convolution 을 여러 층 반복해서 사용하였다. 작은 filter 를 여러 번 쌓으면 큰 filter 와 같은 effective receptive field 를 얻을 수 있다. 예를 들어 3×3 convolution 세 개를 연속으로 쌓으면 7×7 convolution 과 같은 범위의 정보를 볼 수 있다.
- 이 방식의 장점은 두 가지이다. 첫째, 하나의 큰 convolution 을 쓰는 것보다 parameter 수를 줄일 수 있다. 둘째, convolution 사이마다 ReLU 같은 non-linearity 가 들어가기 때문에 더 복잡한 feature 를 표현할 수 있다. 따라서 VGGNet 은 작은 filter 를 깊게 쌓아 receptive field 와 표현력을 확보한 classification 모델이다.

ResNet

- ResNet 은 단순히 CNN 을 깊게 쌓는 것만으로는 성능이 계속 좋아지지 않는다는 문제에서 출발한다. plain CNN 에서는 layer 수가 증가했는데도 training error 와 test error 가 모두 나빠질 수 있다. 이는 overfitting 문제가 아니라, 깊은 네트워크를 최적화하기 어려워지는 degradation problem 이다.
- ResNet 은 이를 해결하기 위해 residual connection 을 사용한다. 일반적인 block 이 원하는 변환 $H(x)$ 를 직접 학습한다면, ResNet 은 $H(x)=F(x)+x$ 와 같이 입력 x 에 residual $F(x)$ 를 더하는 형태를 학습한다. 이 구조에서는 residual branch 가 $F(x)=0$ 에 가까운 출력을 내면 identity mapping $H(x)=x$ 를 쉽게 만들 수 있다. 따라서 깊은 모델이 적어도 얕은 모델의 동작을 유지하는 방향으로 학습될 수 있다.
- 결과적으로 ResNet 은 layer 를 매우 깊게 쌓았을 때 발생하는 optimization difficulty 를 residual mapping 으로 완화하여, 깊은 image classifier 를 효과적으로 학습할 수 있게 만든 구조이다.