

Samsung AI Expert 2025 과정 문제 (과목명: NPU Basics & Open-Source HW)

담당교수: 이재욱

문제 1.

컴퓨터 시스템의 성능은 "Iron Law"으로 알려진 CPU 성능 공식을 통해 분석할 수 있다.

$$\text{CPU Time} = \text{Instruction Count (IC)} * \text{Cycles per Instruction (CPI)} * \text{Clock Cycle Time}$$

동일한 프로그램을 실행하는 두 개의 다른 RISC-V 프로세서 A와 B가 있다. 두 프로세서의 성능 관련 지표는 아래 표와 같다.

지표	프로세서 A	프로세서 B
클럭 속도 (Clock Rate)	2.5 GHz	3.0 GHz
전체 명령어 수 (IC)	1.2×10^9 개	1.5×10^9 개
평균 CPI	1.0	0.8

각 프로세서(A, B)가 프로그램을 완전히 실행하는 데 걸리는 총 CPU 시간(초 단위)을 계산하시오.

답안

CPU 성능 방정식은 다음과 같다:

- $\text{CPU Time} = \text{InstructionCount(IC)} \times \text{CyclesPerInstruction(CPI)} \times \text{ClockCycleTime}$
- $\text{ClockCycleTime} = 1 / \text{ClockRate}$

프로세서 A:

- $\text{Clock Cycle Time} = 1 / (2.5 \times 10^9 \text{ Hz}) = 0.4 \times 10^{-9} \text{ 초}$
- $\text{CPU Time} = (1.2 \times 10^9) \times 1.0 \times (0.4 \times 10^{-9} \text{ 초}) = 0.48 \text{ 초}$


프로세서 B:

- $\text{Clock Cycle Time} = 1 / (3.0 \times 10^9 \text{ Hz}) = 0.333... \times 10^{-9} \text{ 초}$
- $\text{CPU Time} = (1.5 \times 10^9) \times 0.8 \times (0.333... \times 10^{-9} \text{ 초}) = (1.2 \times 10^9) \times (0.333... \times 10^{-9} \text{ 초}) = 0.40 \text{ 초}$

문제 2.

Roofline 모델은 시스템 성능의 병목을 분석하는 데 사용된다. 다음 그림은 세 가지 DNN 모델을 사용한 Google TPUp1의 Roofline 플롯을 보여준다.

(1) 세 가지 DNN 커널(LSTM0, MLP0, CNN0) 각각에 대해 성능 병목 현상(계산 또는 메모리)을 식별하시오.



답안


LSTM0, MLP0 – Memory bandwidth is the bottleneck

CNN0 – Compute is the bottleneck

(2) 메모리 대역폭이 2배 증가하면 새로운 Roofline은 어떻게 변화하는가? 원래 버전의 Roofline과 비교하시오.

답안

Memory BW 라인의 Y 절편이 $+\log_{10}2$ 만큼 위쪽으로 이동함. Peak TOPS는 동일. (아래 그림 참조)




문제 3.


Google TPUv1은 행렬-행렬 곱셈을 계산하기 위해 systolic array 아키텍처를 채택하였다. 이 아키텍처에서 아래의 입력 행렬(X)과 파라미터 행렬(W)의 곱을 계산한다고 가정한다.

$$\begin{pmatrix} y_{11} & y_{12} & y_{13} \\ y_{21} & y_{22} & y_{23} \\ y_{31} & y_{32} & y_{33} \end{pmatrix} = \begin{pmatrix} w_{11} & w_{12} & w_{13} \\ w_{21} & w_{22} & w_{23} \\ w_{31} & w_{32} & w_{33} \end{pmatrix} \begin{pmatrix} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{pmatrix}$$

(1) Systolic array의 입력 X는 어떻게 적용되어야 하는가? 아래 입력 요소(빨간색 원)를 채우시오. 사용하지 않는 상자는 비워 두시오. (힌트: weight 파라미터의 배치에 유의 할 것)



답안



참고: 입력의 y축은 미러링될 수 있음(즉, x_{33} - x_{23} - x_{13} 이 가장 먼저 들어옴). 이 답변도 만점.

(2) 6개의 출력값 (y11부터 y23까지) 각각은 어느 방향으로 나가는가? 그림의 (a)부터 (e)중 하나를 선택하라.

답안

y11, y12, y13 → (a)

y21, y22, y23 → (b)

(3) 마지막으로 출력되는 출력값은 무엇인가?

답안

y23

문제4.

RISC-V는 개방형 표준 ISA로, 모듈화된 구조를 통해 다양한 컴퓨팅 환경에 맞게 확장할 수 있다. ISA의 이름은 지원하는 기능에 따라 표준화된 명명 규칙을 따른다.

(1) **RV64GC**라는 ISA 이름이 의미하는 바를 각 구성요소(RV, 64, G, C)로 나누어 설명하라.

답안

- **RV**: RISC-V 아키텍처임을 나타낸다.
- **64**: 64비트 정수 레지스터 파일과 64비트 사용자 주소 공간을 지원함을 의미한다.
- **G**: "General-purpose"를 의미하며, 기본 정수(I), 정수 곱셈/나눗셈(M), 원자적 명령어(A), 단정밀도 부동소수점(F), 배정밀도 부동소수점(D) 확장을 모두 포함하는 약어이다.
- **C**: 16비트 길이의 압축 명령어(Compressed Instructions) 확장을 지원함을 의미한다.

(2) **RV64GC**에 포함된 'C' 확장 (Compressed Instructions)의 주된 목적은 무엇이며, 이 확장이 특히 임베디드 시스템(embedded systems)에서 어떤 이점을 제공하는지 설명하라.

답안

- **목적**: 'C' 확장의 주된 목적은 전체 프로그램의 코드 크기(code size)를 줄이는 것이다. 자주 사용되는 32비트 명령어들을 16비트 형태로 압축하여 표현한다.
- **이점**:
 1. **비용 절감**: 임베디드 시스템은 종종 메모리(Flash, ROM, SRAM) 용량에 제약이 크다. 코드 크기가 작아지면 동일한 프로그램을 저장하는 데 더 적은 메모리가 필요하므로, 시스템의 하드웨어 비용을 직접적으로 절감할 수 있다.
 2. **성능 향상 및 전력 소모 감소**: 명령어 캐시(I-Cache)에 더 많은 명령어를 저장할 수 있어 캐시 적중률(hit rate)이 높아진다. 이는 메모리 접근 횟수를 줄여 프로그램 실행 속도를 높이고, DRAM이나 플래시 메모리와 같은 상대적으로 전력 소모가 큰 외부 메모리와의 데이터 전송 횟수를 줄여 시스템 전체의 전력 소모를 감소시키는 효과를 가져온다.