

1. Local / Global Interpretability와 Concept-based Explanation

설명가능한 인공지능에서 **local interpretability**와 **global interpretability**의 차이를 설명하고, saliency map 기반 설명과 concept-based explanation의 차이를 논하라.

모범답안

Local interpretability는 개별 입력 사례에 대해 모델이 어떤 근거로 특정 예측을 했는지를 설명하는 데 초점을 둔다. 예를 들어 의료영상 분류 모델에서 특정 X-ray 이미지가 폐렴으로 분류되었을 때, Grad-CAM이나 CAM은 모델이 영상의 어느 영역을 중요하게 보았는지를 heatmap 형태로 보여준다. SHAP은 입력 feature들이 해당 예측에 얼마나 기여했는지를 정량적으로 분석한다. 따라서 local interpretability는 개별 사례에 대한 직관적인 설명을 제공한다는 장점이 있다.

반면 global interpretability는 모델이 전체적으로 어떤 개념, 규칙, 패턴에 의존하여 예측하는지를 설명하려는 접근이다. TCAV는 모델이 특정 인간 친화적 개념, 예를 들어 “줄무늬”, “질감”, “병변 형태”와 같은 개념에 얼마나 민감하게 반응하는지를 분석한다. ACE나 CRAFT는 모델 내부 표현에서 의미 있는 개념을 발견하거나 분해하여 모델의 전반적인 판단 구조를 설명하려 한다.

Saliency map 기반 설명은 시각적으로 직관적이지만, 모델이 실제로 왜 그런 판단을 했는지에 대한 개념적 설명은 부족할 수 있다. 예를 들어 heatmap이 병변 부위를 강조하더라도, 모델이 병변의 형태를 본 것인지, 단순히 주변의 마커나 촬영 조건을 본 것인지는 명확하지 않을 수 있다. 반면 concept-based explanation은 모델이 인간이 이해할 수 있는 개념 단위에 얼마나 의존하는지를 보여 주기 때문에, 모델의 전반적 신뢰성과 편향 여부를 평가하는 데 더 유용할 수 있다.

2. Mechanistic Interpretability와 기존 XAI의 차이

Mechanistic interpretability가 일반적인 feature attribution 또는 saliency 기반 XAI와 구별되는 점을 설명하라.

모범답안

일반적인 XAI 방법은 주로 입력과 출력 사이의 관계를 설명하는 데 초점을 둔다. 예를 들어 saliency map이나 Grad-CAM은 특정 입력 이미지에서 모델이 어느 영역을 중요하게 보았는지를 보여 주며, SHAP은 각 입력 feature가 최종 예측에 얼마나 기여했는지를 계산한다. 이러한 방법들은 모델의 판단 근거를 외부에서 관찰 가능한 형태로 설명하는 데 유용하다.

반면 mechanistic interpretability는 모델 내부에서 실제로 어떤 계산이 일어나는지를 밝히는 것을 목표로 한다. 즉 단순히 “이 입력이 출력에 어떤 영향을 주었다”를 설명하는 것이 아니라, 모델 내부의 뉴런, attention head, layer, circuit, representation 등이 어떤 기능을 수행하며 어떻게 결합되어 최종 출력을 만들어 내는지를 분석하려 한다.

예를 들어 saliency map은 “모델이 이미지의 어느 부분을 보았는가”를 설명하는 데 가깝다. 하지만 mechanistic interpretability는 “모델 내부에서 특정 뉴런이나 attention head가 어떤 개념을 감지하고, 그 정보가 어떤 경로를 통해 최종 판단에 영향을 주었는가”를 설명하려 한다. 따라서 mechanistic interpretability는 더 인과적이고 구조적인 설명을 추구한다고 볼 수 있다.

특히 대규모 언어모델이나 Vision Transformer처럼 복잡한 모델에서는 단순한 입력 중요도 분석만으로 모델의 행동을 충분히 이해하기 어렵다. Mechanistic interpretability는 이러한 복잡한 모델의 내부 작동 원리를 밝히고, hallucination, bias, shortcut learning, unsafe behavior 등을 분석하는 데 중요하다. 그러나 모델 규모가 매우 크고 내부 표현이 고차원적이기 때문에, 모든 뉴런과 회로를 인간이 완전히 해석하는 것은 현실적으로 어렵다는 한계도 있다.

3. 불확실성 관점에서의 모델 신뢰성 평가

머신러닝에서 **aleatoric uncertainty**와 **epistemic uncertainty**의 차이를 설명하고, 설명가능성과 모델 신뢰성 평가의 관계를 논하라.

모범답안

Aleatoric uncertainty는 데이터 자체에 내재된 불확실성에서 비롯된다. 예를 들어 센서 노이즈, 영상의 흐림, 가림 현상, 낮은 해상도, 전문가 간 라벨 불일치 등은 데이터 생성 과정에서 발생하는 불확실성이다. 이러한 불확실성은 같은 종류의 데이터를 단순히 더 많이 수집한다고 해서 완전히 제거되기 어렵다. 따라서 aleatoric uncertainty는 흔히 irreducible uncertainty라고 불린다.

Epistemic uncertainty는 모델의 지식 부족에서 발생한다. 학습 데이터가 부족하거나, 특정 도메인 또는 분포의 데이터를 충분히 학습하지 못했을 때 커진다. 예를 들어 한 병원의 의료영상 데이터로만 학습한 모델이 다른 병원의 장비로 촬영된 영상을 만났을 때 높은

불확실성을 보일 수 있다. 이는 모델이 해당 영역을 충분히 학습하지 못했기 때문이며, 더 다양한 데이터 수집이나 모델 개선을 통해 줄일 수 있다.

XAI 기법은 불확실성을 직접 제거하지는 않지만, 모델의 예측이 신뢰할 만한지 판단하는 데 도움을 줄 수 있다. 예를 들어 의료영상 모델이 높은 confidence로 암을 예측했지만 Grad-CAM 결과가 실제 병변이 아니라 병원 로고나 영상 가장자리를 강조한다면, 모델의 판단은 신뢰하기 어렵다. 이 경우 모델이 질병의 본질적 특징이 아니라 spurious correlation에 의존했을 가능성이 있다.

따라서 불확실성 추정과 XAI는 상호보완적이다. 불확실성 추정은 모델이 얼마나 확신하는지를 알려 주고, XAI는 그 확신의 근거가 타당한지를 보여 준다. 의료 AI나 자율주행 AI처럼 안전성이 중요한 분야에서는 단순히 높은 정확도만으로 충분하지 않으며, 모델이 어떤 상황에서 불확실해지는지, 그리고 어떤 근거로 판단하는지를 함께 분석해야 한다.

4. Adversarial Attack과 Interpretability의 관계

Adversarial attack에서 **targeted attack**과 **untargeted attack**의 차이를 설명하고, adversarial robustness와 interpretability의 관계를 논하라.

모범답안

Adversarial attack은 입력에 사람이 거의 인식하기 어려운 작은 perturbation을 추가하여 모델의 예측을 바꾸는 공격이다. Untargeted attack은 모델이 원래 정답을 맞히지 못하도록 만드는 것이 목적이다. 즉 어떤 잘못된 클래스로 분류되든 상관없이 정답 클래스에서 벗어나게 하면 공격이 성공한다.

반면 targeted attack은 공격자가 미리 지정한 특정 클래스로 모델이 오분류하도록 유도한다. 예를 들어 고양이 이미지를 단순히 고양이가 아닌 다른 것으로 분류하게 만들면 untargeted attack이지만, 반드시 “개”로 분류하게 만들면 targeted attack이다. Targeted attack은 특정한 방향으로 decision boundary를 넘겨야 하므로 일반적으로 untargeted attack보다 어렵다.

목적 함수 관점에서 untargeted attack은 정답 클래스에 대한 loss를 증가시키는 방향으로 perturbation을 찾는다. 반면 targeted attack은 목표 클래스에 대한 loss를 감소시키거나 목표 클래스의 예측 확률을 증가시키는 방향으로 perturbation을 최적화한다. 따라서 targeted attack은 더 정교한 조작을 요구한다.

Adversarial perturbation은 모델의 최종 예측만 바꾸는 것이 아니라 saliency map, Grad-CAM, SHAP과 같은 설명 결과도 왜곡할 수 있다. 이는 XAI 결과 역시 모델의 gradient나

내부 activation에 의존하는 경우가 많기 때문이다. 따라서 공격자는 예측 결과는 유지하면서 설명만 바꾸거나, 반대로 예측과 설명을 동시에 조작할 수도 있다.

XAI는 adversarial vulnerability를 분석하는 데 도움을 줄 수 있다. 예를 들어 adversarial example을 입력했을 때 모델의 attention이나 saliency가 정상적인 객체 영역에서 배경이나 무관한 영역으로 이동한다면, 모델이 취약한 feature에 의존하고 있음을 알 수 있다. 그러나 XAI 자체가 완전한 방어책은 아니다. 설명 결과도 조작될 수 있으며, heatmap이 그럴듯해 보인다고 해서 모델이 반드시 robust하다고 보장할 수는 없다. 따라서 adversarial robustness를 높이기 위해서는 adversarial training, robust feature learning, uncertainty estimation, XAI 기반 검증 등을 함께 활용해야 한다.

5. SmoothQuant와 QuaRot의 activation outlier 처리 방식 차이

SmoothQuant와 QuaRot은 모두 LLM 양자화에서 activation outlier 문제를 해결하려는 방법이다. 두 방법이 activation outlier를 처리하는 방식의 차이를 설명하라.

모범답안

SmoothQuant와 QuaRot은 모두 activation outlier가 LLM 양자화 성능 저하의 중요한 원인이라고 본다. 그러나 두 방법은 outlier를 처리하는 방식이 다르다.

SmoothQuant는 activation outlier를 직접 없애기보다는, 그 부담을 weight 쪽으로 옮기는 방식이다. LLM에서 activation은 입력에 따라 동적으로 변하고 outlier가 심하게 나타나는 반면, weight는 고정되어 있고 상대적으로 분포가 안정적이다. 따라서 SmoothQuant는 diagonal scaling matrix SSS를 사용하여 다음과 같이 변환한다.

$$Y=XW=(XS-1)(SW)Y = XW = (XS^{-1})(SW)Y=XW=(XS-1)(SW)$$

여기서 $XS-1XS^{-1}$ $XS-1$ 은 activation의 큰 outlier 값을 줄여 activation을 INT8로 양자화하기 쉽게 만든다. 반대로 $SWSWSW$ 는 activation에서 줄어든 scale 정보를 weight 쪽으로 옮긴다. 즉 SmoothQuant의 핵심은 **activation의 양자화 난이도를 weight로 이전하는 것이다.**

반면 QuaRot은 outlier를 weight로 옮기는 것이 아니라, orthogonal rotation을 이용해 outlier 에너지를 여러 차원으로 분산시킨다. QuaRot은 randomized Hadamard transform과 같은 회전 행렬 HHH를 사용하여 다음과 같이 표현한다.

$$Y=XW=(XH)(HTW)Y = XW = (XH)(H^T W)Y=XW=(XH)(HTW)$$

여기서 HHH는 orthogonal matrix이므로 벡터의 길이와 내적을 보존한다. 따라서 모델의 계산 결과는 유지하면서, 특정 activation channel에 집중되어 있던 outlier 에너지를 전체 feature dimension으로 퍼뜨릴 수 있다. 이로 인해 activation을 4-bit 수준으로도 더 안정적으로 양자화할 수 있다.

정리하면, SmoothQuant는 **scaling을 통해 activation outlier의 부담을 weight로 이동**시키는 방법이고, QuaRot은 **rotation을 통해 outlier 에너지를 전체 차원에 분산**시키는 방법이다. 따라서 SmoothQuant는 W8A8 양자화에 적합하고, QuaRot은 W4A4KV4처럼 activation과 KV cache까지 포함한 더 낮은 bit-width 양자화를 목표로 한다.
