

1 번 문제

VQA(Visual Question Answering) task 가 무엇인지 설명하고, 일반적인 이미지 분류와 비교했을 때 어떤 점에서 더 복합적인 문제인지와 VQA 모델의 기본 구성요소를 함께 서술하시오.

답

VQA 는 이미지와 질문을 함께 입력받아 질문에 맞는 답을 출력하는 Vision-Language task 이다. 일반적인 이미지 분류와 달리, VQA 는 같은 이미지라도 질문에 따라 필요한 정보와 추론 방식이 달라지므로 이미지와 언어를 함께 이해해야 한다. 따라서 보통 이미지 인코더, 텍스트 인코더, 두 정보를 결합하는 멀티모달 모듈, 그리고 답변 디코더로 구성된다.

2 번 문제

Image captioning 모델은 일반적으로 MLE(Maximum Likelihood Estimation)로 학습되지만, 생성된 캡션이 사람에게서는 부자연스럽게 느껴지거나 이미지의 핵심을 충분히 잘 설명하지 못하는 경우가 있다. 이러한 현상이 발생하는 이유를 간단히 설명하고, 이를 완화하기 위해 사용되는 학습 방법을 서술하시오.

답

MLE 는 정답 캡션의 단어를 순서대로 잘 맞히도록 학습하는 방식이기 때문에, 문장 전체의 자연스러움이나 의미적 적절성보다 단어 수준의 예측 정확도에 더 초점이 맞춰진다. 또한 한 이미지에 대해 가능한 정답 캡션은 여러 개일 수 있는데, 학습은 일부 정답 문장만 기준으로 이루어지고, 실제 평가는 문장 전체의 품질이나 사람의 판단에 의해 이루어지므로 학습 목표와 평가 기준 사이에 차이가 생긴다. 이를 해결하기 위해서는 문장 단위의 보상을 직접 최적화하는 강화학습 기반 방법을 사용할 수 있으며, 대표적으로 policy gradient 나 SCST(Self-Critical Sequence Training) 같은 방법이 사용된다.

3 번 문제

멀티모달 학습에서 cross-modal supervision 과 fusion 은 각각 어떤 목적에서 사용되는지 설명하고, 두 방식이 활용하는 데이터의 성질을 비교하시오.

답

- Cross-modal supervision

- 한 modality 를 다른 modality 의 학습 신호로 활용하는 방식이다.
- 예: 이미지와 텍스트가 함께 있을 때, 텍스트 설명을 이용해 이미지 표현을 학습한다.
- 서로 다른 modality 사이에 공통적으로 포함된 정보인 redundancy 를 활용한다.

- Fusion

- 여러 modality 를 함께 입력으로 사용하여 예측의 강건성을 높이는 방식이다.

- 예: 음성 인식에서 오디오뿐 아니라 영상 정보를 함께 사용하면, 오디오가 **noisy** 한 상황에서도 더 안정적인 예측이 가능하다.
- 각 **modality** 가 서로 다른 보완적 정보를 제공한다는 **complementarity** 를 활용한다.

- 비교

- **Cross-modal supervision** 은 한 **modality** 가 다른 **modality** 의 **supervision** 역할을 할 수 있을 때 적합하다.
- **Fusion** 은 여러 **modality** 를 함께 사용해야 더 정확한 판단이 가능한 상황에 적합하다.