

1. Label 이 부족한 상황에서, 대규모 unlabeled data 로 self-supervised pretraining 을 한 뒤 downstream task 에 fine-tuning 하는 것은 효과적인 weakly supervised learning 방법이다. 그 이유를 (1) label 없이도 대규모 학습이 가능한 이유와 (2) pretraining 된 모델이 downstream task 학습에서 하는 역할을 포함하여 설명하시오.

(정답) (1) Self-supervised pretraining 은 pretext task 를 통해 데이터 자체의 구조로부터 supervision 신호를 만들어내므로, label 없이 값싸게 대량 확보 가능한 unlabeled data 로 대규모 학습이 가능하다. (2) 이렇게 학습된 general 한 representation 은 downstream task 학습의 좋은 initial point(warm-up) 역할을 하므로, 소량의 labeled data 로 fine-tuning 만 해도 좋은 성능에 도달할 수 있다. (결과적으로 비싼 labeled data 요구량이 크게 줄어든다.)

2. In-context learning 은 prompt 에 task 의 demonstration 을 넣어주는 방식으로, gradient 계산도 없고 model parameter 의 update 도 일어나지 않는다. 그럼에도 불구하고 이것을 'learning'이라고 부르는 이유를 한두 문장으로 쓰시오.

(정답) 입력 sequence 가 진행됨에 따라(demonstration 이 주어짐에 따라) 모델의 출력이 달라지기 때문이다. 즉, parameter 는 고정되어 있지만 context 에 의해 모델의 행동(출력)이 변화하므로 learning 이라 부른다.

3. Instruction finetuning 은 LM 을 다양한 task 에 빠르게 적응하게 만드는 핵심 기법이지만, ground-truth 데이터 수집 비용 외에도 근본적인 한계들이 존재한다.
 - a. Instruction finetuning 의 근본적인 한계 두 가지를 설명하시오.
 - b. RLHF(Reinforcement Learning from Human Feedback)는 이 한계들을 어떤 방식으로 해결하고자 하는지 설명하시오.

(정답)

- (a) - 한계 1: 창의적 생성(open-ended creative generation)과 같은 task 는 정답(right answer)이 존재하지 않아, 정답을 맞추도록 학습하는 방식이 적합하지 않다.
 - 한계 2: language modeling objective 는 모든 token-level 오류에 동일한 페널티를 부여하지만, 실제로는 오류마다 심각성이 다르다. 즉, LM objective 와 '인간의 선호를 만족시킨다'는 실제 목적 사이에 mismatch 가 존재한다.
- (b) RLHF 는 정답을 맞추는 대신 인간의 선호(preference)를 직접 최적화 대상으로 삼는다. LM 의 출력 샘플 s 에 대해 인간의 선호를 반영하는 reward $R(s)$ 를 정의하고(높을수록 좋음), 이 reward 의 기대값을 최대화하도록 강화학습으로 LM 을 학습한다. 이를 통해 정답이 없는 task 에서도 학습이 가능하고, 오류의 심각성 차이도 reward 에 반영할 수 있다.