기출예상문제

AI Expert · 시험 문제지

이름: _____ 수험번호: _____ 날짜: _____

응시 안내

- 모든 답안은 각 문제 아래 답안 박스 안에 작성하시오.
- 풀이 과정과 핵심 키워드를 함께 서술하면 가점될 수 있다.
- 답안 박스의 줄 수는 가이드일 뿐이며 박스를 넘겨 작성해도 무방하다.

1부. 인공지능 기초 (260406~260409 / 장병탁 교수님)

문제 1. CNN 출력 크기 및 파라미터 수 계산

다음과 같은 CNN 모델에 MNIST 이미지를 입력한다.

- 입력 이미지 크기 : 1 × 28 × 28 (채널=1, 28×28 픽셀)
- Conv2D : 필터 32개, 커널 3×3, stride=1, padding=0
- MaxPool2D : 커널 2×2, stride=2
- Conv2D : 필터 64개, 커널 3×3, stride=1, padding=0
- MaxPool2D : 커널 2×2, stride=2
- Flatten 후 FC → 10개 클래스 출력

다음을 순서대로 계산하시오. (출력 크기는 정수부 ⌊ ⌋ 로 내림한다.)

1. 첫 번째 Conv2D 직후의 출력 텐서의 공간 크기(H×W)
2. 첫 번째 MaxPool2D 직후의 출력 텐서의 공간 크기(H×W)
3. 두 번째 Conv2D 직후의 출력 텐서의 공간 크기(H×W)
4. 두 번째 MaxPool2D 직후의 출력 텐서의 공간 크기(H×W)
5. Flatten 직후의 벡터 차원 수 (채널 × H × W)
6. 전체 FC 계층의 파라미터 수(가중치 + 바이어스). 단, 직전 Flatten 차원과 10개 출력에 대한 fully-connected 계산이다.

답안

문제 2. RNN의 한계와 LSTM 게이트 구조

강의에서는 시퀀스 데이터를 처리하는 모델로 RNN과 그 개선 모델인 LSTM을 소개하였다.

1. 기본 RNN이 긴 시퀀스를 처리할 때 발생하는 대표적인 학습 문제를 1개 쓰고, 왜 발생하는지 한 줄로 설명하시오.
2. LSTM이 도입한 3개의 게이트(gate) 이름을 모두 쓰고, 각 게이트가 수행하는 역할을 한 줄씩 쓰시오.
3. LSTM이 기본 RNN 대비 갖는 이점을 "장기 의존성(long-term dependency)" 개념과 연결하여 1~2줄로 서술하시오.

답안

문제 3. Scaled Dot-Product Attention 계산

Transformer의 핵심 연산인 Scaled Dot-Product Attention은 다음과 같이 정의된다.

> $\text{Attention}(Q, K, V) = \text{softmax}(\, Q \cdot K^T / \sqrt{d_k}\,) \cdot V$

한 개의 쿼리(Query) 벡터와 2개의 키/값(Key, Value) 벡터가 다음과 같이 주어졌다. (키와 값의 차원 d_k = 2)

> - $Q = [1, 0]$
> - $K_1 = [1, 0]$, $V_1 = [1, 2]$
> - $K_2 = [0, 1]$, $V_2 = [3, 4]$

다음을 순서대로 구하시오. (softmax 계산 시 e ≈ 2.718 을 사용하고, 최종 값은 소수 둘째 자리까지 반올림하여 쓰시오.)

1. $Q \cdot K_1$ 및 $Q \cdot K_2$ 의 내적 점수
2. $\sqrt{d_k}$ 로 나눈 후의 스케일된 점수
3. 두 점수에 대한 softmax 가중치 α_1, α_2
4. 최종 Attention 출력 벡터 ($= \alpha_1 \cdot V_1 + \alpha_2 \cdot V_2$)
5. 위 식에서 $\sqrt{d_k}$ 로 나누어 "스케일"하는 이유를 한 줄로 서술하시오.

답안

문제 4. BERT vs GPT 구조·학습 비교와 In-Context Learning

대표적인 사전학습 언어모델인 BERT와 GPT는 모두 Transformer를 기반으로 하지만 구조와 학습 방식에 차이가 있다.

1. BERT와 GPT는 각각 Transformer의 어떤 부분(Encoder / Decoder)을 사용하는지 쓰시오.
2. 두 모델의 사전학습 목표(pre-training objective)를 각각 쓰시오.
3. 두 모델의 문맥 파악 방향(Bidirectional / Unidirectional)을 각각 쓰시오.
4. 다음 두 태스크는 BERT와 GPT 중 어느 쪽에 더 적합한지 각각 이유와 함께 쓰시오.
   - (가) 문장 빈칸 채우기 / 문장 분류 / 개체명 인식
   - (나) 주어진 프롬프트를 이어 받아 긴 글을 생성하기
5. GPT-3 이후 LLM에서 강조된 In-Context Learning (Few-shot Learning) 의 개념을 한두 줄로 서술하시오.

답안

문제 5. Scaled Dot-Product Attention 계산

Transformer의 attention은 다음 식으로 계산된다.

```
Attention(Q, K, V) = softmax(QK^T / sqrt(d_k))V
```

다음 벡터가 주어져 있다.

```
Q  = [1, 0]
K1 = [1, 0],   V1 = [2, 0]
K2 = [0, 1],   V2 = [0, 2]
d_k = 2
```

다음을 계산하시오. 단, sqrt(2)=1.414, e^0.707≈2.03, e^0=1로 계산하고, 최종 답은 소수 둘째 자리까지 쓰시오.

1. Q·K1, Q·K2 내적 점수
2. sqrt(d_k)로 나눈 scaled score
3. softmax attention weight alpha1, alpha2
4. 최종 Attention 출력 벡터
5. sqrt(d_k)로 나누는 이유를 한 줄로 설명하시오.

답안

문제 6. BERT와 GPT 비교

BERT와 GPT는 모두 Transformer 기반 모델이지만 구조와 학습 방식이 다르다. 다음 물음에 답하시오.

1. BERT와 GPT가 각각 Transformer의 어느 부분을 사용하는지 쓰시오.
2. BERT와 GPT의 사전학습 목표를 각각 쓰시오.
3. BERT와 GPT의 문맥 처리 방향을 각각 쓰시오.
4. 다음 태스크에 더 적합한 모델을 BERT/GPT 중에서 고르고 이유를 쓰시오.
   - 문장 분류 또는 개체명 인식
   - 주어진 문장을 이어서 글 생성
5. GPT 계열 모델에서 말하는 In-Context Learning이 무엇인지 설명하시오.

답안

문제 7. CNN 출력 크기와 Flatten 차원 계산

다음 CNN 모델에 1 x 28 x 28 크기의 MNIST 이미지가 입력된다.

> 입력: 1 x 28 x 28
> Conv2D: 필터 16개, kernel size 5 x 5, stride=1, padding=0
> MaxPool2D: kernel size 2 x 2, stride=2
> Conv2D: 필터 32개, kernel size 3 x 3, stride=1, padding=1
> MaxPool2D: kernel size 2 x 2, stride=2
> Flatten

다음을 순서대로 계산하시오.

1. 첫 번째 Conv2D 후 출력 크기
2. 첫 번째 MaxPool2D 후 출력 크기
3. 두 번째 Conv2D 후 출력 크기
4. 두 번째 MaxPool2D 후 출력 크기
5. Flatten 후 벡터 차원

답안

문제 8. RNN의 한계와 LSTM 게이트

RNN과 LSTM에 대해 다음 물음에 답하시오.

1. RNN이 sequence 데이터를 처리할 수 있는 이유를 hidden state 개념으로 설명하시오.
2. 기본 RNN이 긴 sequence에서 겪는 대표적인 학습 문제를 쓰고, 왜 발생하는지 설명하시오.
3. LSTM의 3가지 gate 이름을 쓰고, 각 역할을 한 줄씩 설명하시오.
4. LSTM 또는 GRU가 기본 RNN보다 긴 context를 더 잘 다룰 수 있는 이유를 설명하시오.

답안

2부. 딥러닝 기초 (260410~260421 / 윤성로 교수님)

문제 9. [생성형 AI 기초]

생성형 모델(Generative Model)과 판별형 모델(Discriminative Model)의 차이를 설명하시오.

답안

문제 10. [VAE (Variational Autoencoder)]

VAE와 일반 Autoencoder(AE)의 구조적 차이를 설명하시오.

답안

문제 11. [VAE (Variational Autoencoder)]

VAE에서 Reparameterization Trick이 왜 필요한지 설명하시오.

답안

문제 12. [VAE (Variational Autoencoder)]

VAE의 목적함수인 ELBO(Evidence Lower Bound)를 구성하는 두 항의 역할을 각각 설명하시오.

답안

문제 13. [GAN (Generative Adversarial Network)]

GAN에서 Generator와 Discriminator의 역할을 각각 설명하시오.

답안

문제 14. [GAN (Generative Adversarial Network)]

GAN의 Minimax 목적함수에서 Generator에 대해 log(1 - D(G(z))) 를 최소화하는 대신 log D(G(z)) 를 최대화하는 Non-saturating Loss를 사용하는 이유를 설명하시오.

답안

문제 15. [GAN (Generative Adversarial Network)]

GAN 학습에서 발생하는 Mode Collapse(모드 붕괴) 현상이 무엇인지 설명하시오.

답안

문제 16. [생성 모델 평가]

FID(Fréchet Inception Distance)가 무엇을 측정하는 지표이며 값이 낮을수록 좋은 이유를 설명하시오.

답안

문제 17. Autoencoder와 VAE의 차이

Autoencoder와 Variational Autoencoder(VAE)의 차이를 latent variable 관점에서 설명하시오.

답안

문제 18. VAE Loss의 두 구성 요소

VAE의 loss는 크게 Reconstruction Loss와 KL Divergence 항으로 구성된다. 두 항의 역할을 각각 설명하시오.

답안

문제 19. Reparameterization Trick

VAE에서 Reparameterization Trick이 필요한 이유를 설명하시오.

답안

문제 20. GAN의 Generator와 Discriminator

GAN(Generative Adversarial Network)에서 Generator와 Discriminator의 역할을 각각 설명하시오.

답안

문제 21. GAN의 Minimax Objective와 Mode Collapse

GAN 학습이 왜 불안정할 수 있는지 설명하고, Mode Collapse가 무엇인지 서술하시오.

답안

문제 22. VAE와 GAN의 장단점 비교

VAE와 GAN을 생성 품질과 다양성 관점에서 비교하시오.

답안

문제 23. Batch Normalization과 Dropout

Batch Normalization과 Dropout의 역할을 각각 설명하고, training mode와 evaluation mode에서 동작이 어떻게 달라지는지 설명하시오.

답안

문제 24. Residual Connection의 필요성

Residual Connection이 깊은 신경망 학습에 도움이 되는 이유를 설명하시오.

답안

3부. 자연어처리 (260427~260504 / 황승원 교수님)

문제 25. [Chain-of-Thought (CoT) — 강사 직접 지목]

다음 prompt에 대해 답하시오.

> Instruction: Tom has 5 apples. He buys 3 more apples and then gives 2 apples to his friend. How many apples does Tom have now?
> Answer:

(1) 위 문제를 Few-shot CoT prompting 으로 풀게 하려면, prompt를 어떻게 작성해야 하는지 예시(rationale 포함)를 1개 이상 추가 하여 작성하시오.

(2) Few-shot CoT가 단순한 standard prompting (답만 출력) 대비 수학 reasoning task에서 성능을 향상시키는 이유 를 설명하시오.

(3) Chain-of-Thought 능력은 모델 사이즈가 일정 임계점을 넘어서야 발현되는 emergent ability로 알려져 있다. 그 이유를 간단히 설명하시오.

답안

문제 26. [Test-Time Scaling — Self-Consistency / PoT — 강사 직접 지목]

LLM의 추론 성능을 향상시키기 위한 다양한 Test-Time Scaling 기법 이 제안되었다.

(1) Self-Consistency (Majority Voting) 가 무엇인지 설명하고, 이것이 Chain-of-Thought (CoT) 와 어떤 관계로 결합되는지 서술하시오.

(2) Self-Consistency는 Test-Time Scaling 의 두 카테고리 (Sequential vs Parallel) 중 어느 쪽에

해당하는가? 그리고 Sequential 쪽 대표 기법 1가지를 함께 제시하시오.

(3) Program-of-Thought (PoT) 가 일반 Chain-of-Thought 와 다른 점을 한 가지 서술하고, PoT가 등장하게 된 LLM의 한계 (왜 LLM이 산술에 약한가) 를 토큰화 관점에서 설명하시오.

답안

문제 27. [BERT의 사전학습 목표 — 미커버 영역]

BERT는 두 가지 사전학습 목표(pre-training objective)를 동시에 학습하였다.

(1) Masked Language Modeling (MLM) 와 Next Sentence Prediction (NSP) 이 각각 무엇인지 설명하시오.

(2) GPT의 학습 목표 (Causal / Autoregressive Language Modeling) 와 비교하여, BERT가 양방향 (bidirectional) 표현을 배울 수 있는 이유를 설명하시오.

답안

문제 28. [Self-Refinement (Self-Reflection) — Test-Time Scaling Sequential]

LLM이 한 번에 답을 생성하는 대신 자기 출력을 스스로 평가하고 개선 하는 방식이 최근 에이전트의 핵심 기술로 사용되고 있다.

(1) Self-Refinement / Self-Reflection 절차를 Generate → Critique → Refine 의 흐름으로 설명하시오.

(2) Self-Refinement가 하나의 동일한 모델만 사용 함에도 효과를 내는 이유를 "Initial Generation Task vs Critique Task vs Refinement Task" 능력 차이 관점에서 서술하시오.

답안

문제 29. [Chain-of-Thought (CoT)]

(1)

> Instruction: Anna has 4 oranges. She buys 5 more, then eats 1.
> How many oranges does Anna have now?
> Answer: Anna started with 4. She bought 5, so 4 + 5 = 9.
> She ate 1, so 9 - 1 = 8. The answer is 8.
>
> Instruction: Tom has 5 apples. He buys 3 more apples and then gives 2 apples to his friend. How many apples does Tom have now?
> Answer:

핵심 채점 포인트: 예시(Q-A 페어)에 reasoning rationale (계산 과정)이 포함되어 있고, 그 다음 target 문제를 자연스럽게 이어서 배치할 것.

(2)

답안

문제 30. [Test-Time Scaling — Self-Consistency / PoT]

(1)

답안

문제 31. [BERT의 사전학습 목표]

(1)

답안

문제 32. [Self-Refinement / Self-Reflection]

(1)

답안

문제 33. Language Model과 Autoregressive Generation

다음 질문에 답하시오.

(1) 언어 모델(Language Model)의 원래 정의를 확률 관점에서 설명하시오.

(2) 문장 확률 $P(w_1, w_2, \dots, w_T)$를 next-token probability의 곱으로 분해하여 표현하시오.

(3) Autoregressive generation이 무엇인지 설명하고, BERT와 GPT 중 어느 모델이 이에 더 직접적으로 해당하는지 쓰시오.

답안

문제 34. Pre-training, Instruction Tuning, RLHF의 차이

LLM이 사용자의 지시를 잘 따르는 assistant가 되기까지의 학습 과정을 다음 세 단계로 나누어 설명하시오.

(1) Pre-training

(2) Instruction Tuning 또는 SFT

(3) RLHF

또한 pre-training만 수행한 GPT-3류 모델이 사용자의 질문에 바로 답하지 못하고 text completion처럼 동작할 수 있는 이유를 설명하시오.

답안

문제 35. T5의 Text-to-Text Framework와 Prefix

T5(Text-to-Text Transfer Transformer)에 대해 다음 질문에 답하시오.

(1) T5는 Transformer 기반 모델 분류 A) Encoder-only, B) Decoder-only, C) Encoder-Decoder 중 어디에 속하는가?

(2) T5의 text-to-text framework가 무엇인지 예시와 함께 설명하시오.

(3) T5에서 task prefix를 붙이는 이유를 설명하시오.

답안

문제 36. T5 Span Corruption과 일반 Language Modeling 비교

T5의 pre-training objective와 관련하여 다음 질문에 답하시오.

(1) Span corruption이 무엇인지 설명하시오.

(2) 일반적인 autoregressive language modeling과 span corruption의 차이를 설명하시오.

(3) 왜 span corruption이 encoder-decoder 모델 학습에 도움이 될 수 있는지 설명하시오.

답안