기출확정문제_답안

AI Expert · 모범 답안

1부. 인공지능 기초 (260406~260409 / 장병탁 교수님)

문제 1. A* 평가함수 계산

정답

1. f(n)=g(n)+h(n)= 5 + 3 = 8 이다.

2. A*는 평가값 f(n) 이 가장 작은 노드를 우선 확장한다. 이 노드의 값은 8 이므로, 열린 노드들 중 값이 7 인 노드가 있다면 그 노드가 먼저 확장된다. 따라서 이 노드가 가장 먼저 확장되지는 않는다.

문제 2. 추론 규칙 적용

정답

1. 변수 치환 결과: x=John,y=Brian이므로
   Father(John,Brian)→Male(John)∧Adult(John)
2. 적용한 추론 규칙 이름: Modus Ponens
3. 중간 결론: Male(John)∧Adult(John)
4. 최종 결론: Adult(John)

문제 3. 튜링 테스트와 중국어 방 논증 구분

정답

1. 튜링 테스트의 관점

   - 이유: 외부에서 관찰 가능한 대화 행동을 기준으로 기계 지능을 판단하기

때문이다.

2. 중국어 방 논증의 관점

   - 이유: 형식적 기호 조작만으로는 의미 이해나 마음이 생기지 않는다고 보기

때문이다.

문제 4. PEAS 를 이용한 에이전트 설계

정답

● Performance: 문서를 정확한 사람에게 전달하는 것, 충돌 없이 안전하게 이동하는 것, 가능한 짧은 시간 안에 임무를 수행하는 것
● Environment: 사무실 내부 복도와 방, 책상과 의자 같은 장애물, 엘리베이터나 문, 직원과 방문자 같은 사람들
● Actuators: 바퀴 또는 구동 모터, 로봇 팔이나 집게, 문서 적재함 제어 장치, 화면이나 스피커
● Sensors: 카메라, 거리 센서 또는 라이다, 위치 추정을 위한 센서, 사람이나 물체 인식을 위한 비전 센서, 마이크 또는 터치 입력 장치

문제 5. Backpropagation in a 2-Layer MLP

정답

(5-1) Forward Pass

$z_1 = w_1 x + b_1 = 1 \times 2 + 0 = 2$

$a_1 = \mathrm{ReLU}(2) = 2$

$z_2 = w_2 a_1 + b_2 = 2 \times 2 + 0 = 4$

$\hat{y} = 4$

$L = 1/2\ (4 - 1)^2 = 1/2 \times 9 = 4.$

(5-2) Backpropagation

먼저 출력층부터 계산한다.

$\partial L/\partial \hat{y} = (\hat{y} - y) = (4 - 1) = 3$

Output layer

$\partial L/\partial w_2 = \partial L/\partial \hat{y} \times \partial \hat{y}/\partial w_2$

$= 3 \times a_1 = 3 \times 2 = 6$

$\partial L/\partial b_2 = \partial L/\partial \hat{y} \times 1 = 3$

Hidden layer

$\partial L/\partial a_1 = \partial L/\partial \hat{y} \times w_2 = 3 \times 2 = 6$

$\mathrm{ReLU}'(z_1) = 1\ (z_1 = 2 > 0)$

$\partial L/\partial z_1 = 6 \times 1 = 6$

$\partial L/\partial w_1 = \partial L/\partial z_1 \times x = 6 \times 2 = 12$

$\partial L/\partial b_1 = \partial L/\partial z_1 \times 1 = 6$

(5-3) Parameter Update

w_2_new = 2 - 0.1 × 6 = 1.4

b_2_new = 0 - 0.1 × 3 = -0.3

w_1_new = 1 - 0.1 × 12 = -0.2

b_1_new = 0 - 0.1 × 6 = -0.6

(최종 답)

w_1 = -0.2

b_1 = -0.6

w_2 = 1.4

b_2 = -0.3

문제 6. 층별 선훈련 (Layer-wise Pretraining)

정답

층별 선훈련(layer-wise pretraining)은 신경망을 한 번에 학습하는 대신,

각 층을 순차적으로 학습한 후 전체 네트워크를 미세조정(fine-tuning)하는 방법이다.

주로 Restricted Boltzmann Machine(RBM)이나 autoencoder를 사용하여 비지도 학습으로 초기 가중치를 설정하였다.

이 방법은 깊은 신경망에서 발생하는 gradient vanishing 문제를 완화하고,

랜덤 초기화 대신 의미 있는 초기값을 제공함으로써 학습을 안정적으로 만들었다.

따라서 층별 선훈련은 딥러닝이 효과적으로 학습될 수 있도록 한 초기 핵심 기술로서 혁신적이었다.

[채점 포인트]

- layer-wise 학습 설명 ✔
- unsupervised pretraining 언급 ✔
- vanishing gradient 완화 ✔
- deep network 학습 가능하게 함 ✔

2부. 딥러닝 기초 (260410~260421 / 윤성로 교수님)

문제 7. [Machine Learning 기초]

정답

지도 학습은 입력 데이터와 정답 레이블이 함께 주어져 입력→출력 매핑을 학습하는 방식이다. 비지도 학습은 레이블 없이 데이터의 구조나 패턴(군집화, 차원 축소 등)을 스스로 학습하는 방식이다.

문제 8. [Machine Learning 기초]

정답

모델이 훈련 데이터에 지나치게 맞춰져 훈련 성능은 높지만 새로운 데이터에서 성능이 크게 떨어지는 현상이다. 데이터의 노이즈까지 학습하여 일반화(Generalization) 능력이 낮아지기 때문에 문제가 된다.

문제 9. [Optimization & Regularization]

정답

손실 함수의 기울기(Gradient)를 계산하고, 기울기의 반대 방향으로 파라미터를 학습률(ε)만큼 업데이트하여 손실 함수의 최솟값을 찾아가는 최적화 알고리즘이다.

문제 10. [Optimization & Regularization]

정답

L1(Lasso)은 가중치 절댓값의 합을 패널티로 추가해 일부 가중치를 정확히 0으로 만드는 희소 모델을 유도한다. L2(Ridge)는 가중치 제곱합을 패널티로 추가해 가중치를 0에 가깝게 줄이지만 완전히 0이 되지는 않는다.

문제 11. [MLP (다층 퍼셉트론)]

정답

활성화 함수는 신경망에 비선형성(Non-linearity)을 부여하기 위해 필요하다. 없으면 층을 아무리 많이 쌓아도 결국 하나의 선형 변환과 동일해져 복잡한 패턴을 표현하지 못한다.

문제 12. [MLP (다층 퍼셉트론)]

정답

출력층에서 계산된 손실(Loss)을 기반으로 연쇄 법칙(Chain Rule)을 이용해 각 층 가중치의 기울기를 출력층→입력층 방향으로 효율적으로 계산하는 알고리즘이다. 이 기울기로 경사 하강법을 통해 가중치를 업데이트한다.

문제 13. [CNN (합성곱 신경망)]

정답

필터를 이미지의 모든 위치에 슬라이딩하며 적용해 지역적(Local) 특징을 추출하고, 같은 필터를 전체에 공유(Weight Sharing)하여 파라미터 수를 줄이며 위치 불변성(Translation Invariance)을 얻을 수 있다.

문제 14. [CNN (합성곱 신경망)]

정답

특징 맵(Feature Map)의 공간적 크기를 줄여 계산량과 파라미터 수를 감소시키고, 작은 위치 변화에 강인한(Robust) 표현을 만든다. Max Pooling과 Average Pooling이 주로 사용된다.

문제 15. [RNN & LSTM]

정답

RNN은 이전 시간 단계의 은닉 상태(Hidden State)를 현재 입력과 함께 사용하여 시퀀스 데이터의 시간적 문맥을 처리한다. MLP는 각 입력을 독립적으로 처리하므로 순서 정보를 반영하지 못한다.

문제 16. [RNN & LSTM]

정답

기본 RNN에서 발생하는 기울기 소실(Vanishing Gradient) 문제를 해결하기 위해 등장했다. 셀 상태(Cell State)와 Forget·Input·Output 게이트 구조를 통해 장기 의존성(Long-term Dependency)을 효과적으로 학습한다.

문제 17. [Transformer]

정답

시퀀스 내 각 위치가 다른 모든 위치와 얼마나 관련 있는지 가중치를 계산하여, 중요한 위치에 더 집중하는 방식으로 문맥 정보를 반영한다. 멀리 떨어진 토큰 사이의 의존성도 직접 포착할 수 있다.

문제 18. [Transformer]

정답

Transformer는 입력을 병렬로 처리하므로 RNN과 달리 토큰의 순서가 자동으로 반영되지 않는다. 위치 인코딩은 각 토큰의 위치 정보를 임베딩에 더해 모델이 순서를 인식할 수 있게 해준다.

3부. 자연어처리 (260427~260504 / 황승원 교수님)

문제 19. RNN 모델 파라미터 차원 계산

정답

row, column 이 바뀌어도 정답임. 예: 100 × 12000 과 12000 × 100은 동일함

파라미터 이름	차원 (Dimensionality)	설명
W_{xh}	100 × 12,000	input x_t는 12,000차원 (one-hot), hidden state는 100차원
W_{hh}	100 × 100	이전 hidden state에서 다음 hidden state로
W_{hy}	3 × 100	hidden state → 3개 클래스 출력
b_h	100 × 1 또는 100	hidden state에 더해지는 bias 벡터

문제 20. RNN 5가지 구조 유형과 Seq2Seq

정답

(1)

1. One-to-one: 이미지 분류, 단어 감정 분석 등
2. One-to-many: 이미지 캡셔닝, 키워드 기반 문장 생성 등
3. Many-to-one: 감정 분석, 스팸 분류, 문장 주제 분류 등
4. Many-to-many (Enc-Dec): 기계 번역, 텍스트 요약, 질문 생성, 대화 응답 생성 등
5. Many-to-many: POS 태깅, NER 등

(2)

- a) Many-to-many (Enc-Dec)
- b)
- 입력/출력 시퀀스 길이가 달라도 처리 가능 *(Point. 입출력 길이 달라도 됨이라는 의미)*
- 전체 입력 문맥을 반영하여 출력 생성 가능 *(Point. 전체 입력 문맥 반영 의미)*

문제 21. Attention 메커니즘

정답

(1)

기본 Encoder-Decoder 구조에서는 입력 시퀀스 전체 정보를 고정된 길이의 하나의 벡터(context vector) 로 압축하여 디코더에 전달함.
입력 문장이 길거나 복잡할 경우, 이 하나의 벡터만으로 모든 정보를 담기 어렵고, 결과적으로 정보 손실이 발생함 → 성능 저하

(2)

Attention은 입력 시퀀스의 모든 hidden state를 참조하며, 각 디코딩 스텝마다 현재 디코더 상태와 입력 시퀀스의 각 hidden state 간의 유사도(attention score)를 계산함.
이 유사도를 기반으로 가중합(context vector)을 동적으로 계산하여, 매 스텝마다 중요한 입력 정보를 선택적으로 반영함 → 정보 손실 없이 더 정확한 출력 가능

문제 22. Transformer 기반 모델 분류 (BERT vs GPT)

정답

(1) BERT: A) Encoder-only, GPT: B) Decoder-only

(2)

- i) BERT는 task마다 fine-tuning이 필요했지만, GPT는 task 마다 fine-tuning 없이 general 한 적용이 가능했음.

(채점 point: BERT는 task 마다 fine-tuning이 필요 / GPT는 task 마다 fine-tuning 할 필요가 없음.)

- ii) Next-Token Prediction

(3) search based 기법은 확률 분포에서 가장 높은 확률을 가진 토큰을 확정적으로 고르며, sampling based 기법은 확률 분포에 따라 확률적으로 토큰을 샘플링함.
(채점 point: search based — 가장 높은 확률 토큰 + 확정적, sampling based — 확률적으로 토큰 샘플링)

문제 23. Transformer 인코더 블록 파라미터 개수 계산

정답

항목	파라미터 수	차원 설명
W_q	100	$2 \times (5 \times 10)$
W_k	100	$2 \times (5 \times 10)$
W_v	100	$2 \times (5 \times 10)$
W_o	100	10×10
Feedforward-1	300	30×10
Feedforward-2	300	10×30
총합	1000	

문제 24. In-Context Learning과 Zero-shot CoT Prompting

정답

(1)

- a) 모델 크기가 클수록 일반적으로 In-context learning 성능이 증가한다.
- b) shot의 개수가 많을수록 일반적으로 성능이 증가하지만, 예시의 품질이 낮거나 context length 한계를 넘으면 성능 향상이 제한될 수 있다.

(2) Zero-shot CoT prompting은 예시 없이 모델에게 reasoning을 유도하는 문구를 추가하는 방식이다. 따라서 아래와 같은 답이 모두 가능하다.

a)

> Instruction: Amy bought 2 bottles of water and 3 ice creams. Water is 500 won and ice cream is 1000 won. What's the total price?
> Answer: Let's think step-by-step.

b)

> Instruction: Amy bought 2 bottles of water and 3 ice creams. Water is 500 won and ice cream is 1000 won. What's the total price? Generate the answer with rationale.
> Answer:

문제 25. Pairwise Preference와 RLHF / DPO

정답

(1) 만들 수 있는 pairwise preference label은 다음과 같다.

$$
y_2 > y_1, \quad y_1 > y_3, \quad y_2 > y_3
$$

(2) RLHF에서는 위 pairwise preference 데이터를 이용해 Reward Model을 학습한다.
Reward Model은 같은 입력 x에 대해 사람이 더 선호한 답변에는 더 높은 reward를, 덜 선호한 답변에는 더 낮은 reward를 주도록 학습된다.

그 후 언어모델은 이 Reward Model의 점수가 높은 답변을 생성하도록 PPO와 같은 강화학습 방식으로 최적화된다.

(3) DPO에서는 별도의 Reward Model을 학습하지 않는다.
대신 선호된 답변 y^+의 생성 확률은 높이고, 거부된 답변 y^-의 생성 확률은 낮추도록 언어모델을 직접 학습한다.

문제 26. RLHF의 PPO 최적화 — Reward Model & KL Penalty

정답

(1)

Reward Model은 사람이 선호하는 답변일수록 높은 점수를 주도록 학습되며, 언어모델이 더 좋은 답변을 생성하도록 학습 방향을 제공한다.

(2)

KL divergence penalty는 학습된 모델이 기존 사전학습 모델의 분포에서 너무 크게 벗어나지 않도록 제한한다. 이를 통해 학습 안정성을 유지하고 비정상적인 출력이 생성되는 것을 방지한다.